

 Centro Universitário SENAI Santa Catarina	AVALIAÇÃO PRÁTICA		Desempenho
	Data: 24/04/2026		
	Docente: Eric Tomas Zancanaro		
	Curso: CDIA		
	Unidade Curricular: BI e DV		
	Turma: GR GRCD 2025/1 M1		
	Estudante:		
Orientações gerais: . A tarefa deve ser iniciado em sala e entregue via AVA . A entrega deve ser feita até o dia 03/05 . Este trabalho comporá a nota de atividades EaD			

CAPACIDADES
1. Aplicar técnicas de otimização para o desempenho do sistema. 2. Implementar técnicas de redução de dimensionalidade 3. Criar gráficos e relatórios que facilitem a interpretação dos dados 4. Executar processos de limpeza e tratamento de valores faltantes 5. Validar a integridade dos dados antes da visualização e análise 6. Realizar pré-processamento de dados, incluindo limpeza e normalização. 7. Implementar processos de ETL para alimentar os dashboards.

CONTEXTUALIZAÇÃO
O Banco Mundial compila um conjunto de estatísticas relevantes para análises no desenvolvimento global e na luta contra a pobreza. Esta compilação, conhecida como Indicadores de Desenvolvimento Global (WDI), consiste de mais de 1400 séries temporais, incluindo mais de 50 anos de dados sobre 217 economias e grupos de países. Este dataset nos permite analisar não só a progressão individual de cada país, mas também realizar comparações internacionais entre as diferentes métricas. Um ponto interessante de análise é como cada conjunto de países se comportou durante uma crise internacional, como a epidemia do COVID-19.

DESAFIO
Consuma, limpe, processe e analise o dataset WDI. Neste processo, você deverá utilizar técnicas de limpeza de dados, normalização, <i>feature engineering</i> e redução de dimensionalidade. A turma será dividida em 2 seções: 1. Esta seção analisará os dados do período 2013 a 2018. 2. Esta seção analisará os dados no período da pandemia: 2019 a 2023. Para cada período, será necessário extrair as características relevantes para agrupar os países em um gráfico de dispersão. Escolha, entre as 1488 <i>features</i> do dataset, colunas apropriadas para os seguintes pilares: ● Pilar Econômico: PIB per capita, Inflação, Exportações, etc... ● Pilar de Saúde: Expectativa de vida, Mortalidade infantil, Gastos em saúde, etc... ● Pilar de Educação/Social: Taxa de alfabetização, Acesso à internet, População urbana, etc... ● Pilar Ambiental: Emissões de CO2 per capita, Consumo de energia, etc... Use o dicionário de dados para identificar as features adequadas e gere um dataframe contendo apenas estas colunas. ● Ao escolher os dados, preste atenção na necessidade de análise e nas perguntas que devem ser respondidas. ● Atente-se também ao volume de dados faltantes. Por exemplo, faz sentido escolher uma <i>feature</i> onde mais de 40% dos países apresentam valores nulos? ● Um número interessante de colunas para a análise está entre 12 e 18. Com as <i>features</i> escolhidas, aplique a redução de dimensionalidade via PCA para gerar o gráfico de dispersão usando os 2 primeiros componentes principais como eixos. Além disso, use o processo de <i>feature engineering</i> para responder aos seguintes questionamentos: Questão 01: Interpretação do PCA

A aplicação do PCA gera novas características (componentes principais) que são combinações lineares das características originais do dataset. Essas combinações lineares associam cada *feature* a um **peso** (loading), que representa a importância daquela característica na construção do componente principais. Analise os pesos dos componentes principais escolhidos para o gráfico de dispersão e elabore uma síntese daquele componente. Por exemplo, se o **PC1** tem pesos altos para PIB, Internet e Eletricidade, esse componente poderia ser descrito como "**Índice de Riqueza e Tecnologia**".

Questão 02: Criação de Índice de Eficiência de Saúde

O gasto total com saúde pode ser alto apenas porque a população é grande. Utilize Pandas para criar uma feature chamada `Eficiencia_Saude`, que seja a razão entre a `Expectativa_de_Vida` e o `Gasto_Saude_Per_Capita`. O que essa métrica revela sobre países com orçamentos limitados, mas bons resultados de longevidade?

Questão 03: Binarização e Categorização (Discretização)

Crie uma variável categórica chamada `Nivel_Industrial`. Se a soma de `Exportacoes` e `Consumo_Energia` estiver acima do percentil 75, classifique como 'Alta'; abaixo de 25, como 'Baixa'; e o restante como 'Média'. Como essa nova feature ajuda a colorir os pontos no seu gráfico de PCA?

Questão 04: Normalização Condicional

Países muito populosos distorcem métricas absolutas. Normalize todas as colunas de 'Consumo Total' dividindo-as pela coluna 'Populacao_Total'. Compare os resultados do PCA antes e depois dessa normalização *per capita*. A variância explicada pelo primeiro componente aumentou ou diminuiu?

Questão 05: Tratamento de Skewness (Assimetria)

Variáveis econômicas como o PIB costumam ter uma distribuição de cauda longa. Gere um histograma para visualizar os dados do PIB no dataset original. Aplique uma transformação logarítmica (`np.log`) na coluna de PIB, gere um novo histograma e compare o histograma antes e depois. Como essa transformação afeta a sensibilidade do PCA a países extremamente ricos (outliers)?

RESULTADOS E ENTREGAS

As entregas devem ser realizadas em um conjunto de arquivos *jupyter notebooks* (.ipynb). O código fonte e as análises devem ser incluídas no mesmo arquivo e anexadas no AVA. O arquivo entregue deve conter obrigatoriamente:

- ✓ Seleção de atributos, limpeza e pivotamento do dataset
- ✓ Normalização e aplicação do PCA
- ✓ Gráfico de dispersão utilizando os 2 primeiros componentes principais
- ✓ Respostas dos 5 questionamentos levantados, intercalados com o código fonte utilizado para chegar a resposta

Todos os scripts devem estar organizados em um único projeto, utilizando nomenclaturas coerentes e evitando importações de bibliotecas e módulos desnecessários. Não é permitida a inclusão de bibliotecas de IA (*scikit-learn*, *tensorflow*, etc.) nesta atividade.

LISTA DE ANEXOS

Anexo A: [Exemplo de PCA aplicado à notas sintéticas](#)

Anexo B: [Notebook exemplo de aplicação do PCA ao dataset](#)

LISTA DE VERIFICAÇÃO
