

Roteiro de Aula: Transformação II: Feature Engineering e Redução de Dimensionalidade (PCA)

Guias Gerais

- Revisão do fluxo de dados (pipeline)
- Reforço das transformações vistas até o momento
- Apresentação de Feature Engineering
- Discretização de dados
- Técnicas de redução de dimensionalidade
- Aplicações práticas em IA

Referências

Revisão

- Limpeza:
 - Tratar dados faltantes
 - Reduzir ruído
 - Eliminar duplicação
- Manipulação:
 - Normalizar
 - Discretizar <--
 - Criar atributos (*feature engineering*) <--
- Redução:
 - Redução de dimensionalidade <--
 - Redução de volume
 - Equilíbrio

Feature Engineering

Feature engineering é um termo bonito para um conceito relativamente simples. Ele codifica a ideia de criar novos atributos (características, variáveis) a partir dos dados existentes. Isso se dá através da manipulação destas características para atingir alguns objetivos.

Quando criamos uma coluna de PIB per capita, dividindo o PIB de um país pela sua população, estamos fazendo *feature engineering*.

É uma área muito abrangente, que usualmente envolve conhecimento específico da área fim: se desejamos aplicar os dados em um modelo de *machine learning*, nós usamos técnicas voltadas a essa finalidade. Para uma análise ou visualização de dados, talvez outras técnicas sejam mais apropriadas.

Como introdução a essa área, veremos as categorias mais frequentes de ações de feature engineering:

- Imputação
- Discretização
- Codificação

- Transformação de Variável
- Transformação de Outliers

Imputação

A ideia de imputação já foi apresentada quando tratamos de limpeza de dados. Refere-se a ação de atribuir valores as observações que estão nulas. Podemos sintetizar as técnicas de imputação de dados em alguns métodos usuais:

Imputação por Tendência Central

Neste método substituímos os nulos por uma estatística de tendência central, nominalmente: média, mediana ou moda. A estatística mais apropriada vai depender de algumas características do nosso dataset. A ideia aqui é que, se a ausência dos dados é aleatória, estaríamos substituindo as ausências pelo valor mais comum no dataset.

A moda deve ser utilizada para substituição de valores categóricos. Isto porque é a única medida

Para dados com distribuição normal, ou gaussiana, a média é um valor apropriado. Isso porque aplicá-la aos registros nulos não tem um efeito drástico na distribuição dos valores em nosso dataset. Não podemos dizer o mesmo quando os dados tem uma tendência à esquerda ou a direita.

Nos demais casos, a mediana pode ser usada para substituir estes valores nulos e reduzir o efeito na distribuição de valores do dataset.

É importante notar que essa técnica é apropriada quando supomos que a ausência dos valores é aleatória e quando o número de registros nulos é baixo. Quando o número de registros ausentes é alto, o uso das medidas de centralidade **distorce a distribuição** e a **variância** dos nossos dados.

Imputação por Amostra Aleatória

Neste método os dados ausentes são substituídos por uma amostra aleatória. Ao utilizar métodos adequados de amostragem, esta estratégia tende a preservar a distribuição original dos dados.

É importante notar que uma nova amostra deve ser escolhida para cada valor nulo. Em especial, quando tratamos de dados categóricos, a nova amostra deve ser feita nos dados incluindo as substituições anteriores.

Imputação por Valor Arbitrário

Aqui escolhemos um valor arbitrário para representar os registros com números faltantes. Este valor deve ser repetido para todas as observações com dados faltantes.

Para dados numéricos, é comum utilizar os valores -1, quando o intervalo da variável é positivo, 999 ou -999 por convenção. É importante que o valor arbitrário **não seja uma ocorrência comum** nos dados originais.

Muito aplicável para dados que servem como fonte de modelos baseados em árvore de decisão, que podem "isolar" o valor arbitrário.

Esta metodologia é apropriada quando a ausência dos dados é explicada por causas específicas, ou quando o volume de dados faltantes é significativamente alto. Deve ser utilizada com cuidado quando os dados são fonte de um modelo linear, visto que distorcerá significativamente a distribuição da variável.

Indicador Booleano

Em adição as técnicas anteriores, é possível criar uma *feature* que serve como um indicador de ausência nos dados. A ideia por trás desse método é que, se a ausência do dado for significativa, o modelo gerado capture essa importância através deste indicador.

Um indicador booleano deve sempre ser utilizado em conjunto com um dos métodos anteriores de imputação.

Importante: Para modelos de Machine learning, as medidas de tendência devem ser calculadas **após** a divisão dos dados em conjunto de treino e de validação. Se calculadas antes, temos um caso de *vazamento* de informação do conjunto de testes para o conjunto de treino, enviesando o modelo resultante.

As medidas são calculadas no conjunto de treinamento e **propagadas** para os dados de teste, evitando o vazamento de informação.

Discretização

Existem situações onde precisamos transformar variáveis contínuas em variáveis discretas. Por exemplo, se desejamos fazer uma análise sobre a renda e comparar diferentes grupos de observações, agrupar pelos valores exatos de cada indivíduo seria um fator de complicação, dada a grande variação de valores individuais. Nesse caso, uma alternativa apropriada seria definir *faixas de renda* para agrupar os indivíduos e realizar nossa análise.

A definição dessas faixas de renda é o que chamamos de discretização. Existem 4 estratégias principais de definição destas categorias:

Divisão em Intervalos Iguais

Seguindo esse método, definimos um conjunto de categorias de forma que todas abranjam um intervalo de dados de mesmo tamanho. No exemplo da faixa de renda, poderíamos utilizar como métrica o salário mínimo, definindo os intervalos até 1 salário, de 1 a 2 salários, de 2 a 3, etc...

Não existe uma regra fixa para determinar o número de categorias desejadas, mas usualmente um número inferior a 10 é desejado. Um detalhe importante é que usualmente podemos expandir a primeira e a última categoria para incluir valores discrepantes (*outliers*). No nosso exemplo, a última categoria poderia ser *acima de 8 salários*, por exemplo.

Divisão em Frequências Iguais

Ao invés de criar faixas de intervalo de mesmo tamanho, essa estratégia prioriza criar categorias com um número similar de observações em cada. Este método é especialmente interessante quando desejamos categorizar nossos dados em um número pré-determinado de categorias.

Se quiséssemos dividir nossos dados de faixa salarial em 4 grupos distintos, cada categoria conteria 25% das observações totais. Essa discretização em 4 categorias é baseada nos *quartis* dos dados.

A maior vantagem dessa técnica é que ela distribui as observações igualmente em todas as categorias. Isso é importante quando a distribuição dos valores tem uma tendência a uma das pontas. Nesse caso, se

usássemos a divisão em intervalos iguais, teríamos uma categoria superrepresentada.

Divisão por Conhecimento da Área

Em casos onde a variável apresenta grupos bem compreendidos na área de análise, essa opção pode gerar uma ótima representação do nosso dataset. Nesse método, utilizamos conhecimento específico da área para definir os limites de nossas categorias.

Continuando no exemplo da faixa salarial, poderíamos utilizar as faixas que definem as classes sociais no Brasil para definir nossas categorias: Classe Baixa (D e E): Renda familiar abaixo de R\$ 3,5 mil. Classe Média Baixa (C): Renda familiar mensal entre R\$ 3,5 mil e R\$ 8 mil. Classe Média Alta (B): Renda familiar mensal entre R\$ 8 mil e R\$ 26 mil. Classe Alta (A): Renda familiar acima de R\$ 26 mil.

Divisão por Algoritmo de Árvore

Nesse modelo deixamos a definição dos limites de cada categoria por conta de um modelo de machine learning baseado em árvores de decisão. Para aplicar esse modo de divisão, precisamos definir um alvo (o que a árvore deve prever) e fornecer o conjunto de dados da variável como entrada no treinamento.

O ideal é utilizar uma árvore com profundidade limitada para evitar os riscos de *overfitting*. Após o treinamento, os limites das categorias são extraídos dos nós de decisão da árvore.

Uma das vantagens desse método é que ele lida com valores discrepantes automaticamente, sem necessidade de ação direta.

Codificação

Se a discretização transforma variáveis categóricas em variáveis contínuas, a codificação nos dá o caminho inverso. Esta técnica é utilizada principalmente quando precisamos alimentar modelos de machine learning que dependem de dados numéricos, mas também é útil para codificar ordenação de categorias, anonimização e padronização dos dados.

One-Hot Encoding

Neste modelo criamos 1 nova coluna para cada categoria existente no nosso dataset. Por exemplo, se temos as categorias *red*, *blue*, *green*, adicionaríamos 3 colunas ao nosso dataset. A variável original seria representada nessas 3 colunas, adicionando o valor **1** naquela que representa a categoria original, e 0 nas demais.

Um cuidado deve ser tomado quando temos muitas categorias no nosso dataset: utilizar one-hot encoding gerará uma matriz esparsa (a maioria dos valores será 0), gerando uma ineficiência na representação e no armazenamento. Esta estratégia também pode levar a uma expansão excessiva das dimensões do nosso dataset.

Codificação Ordinal

Quando uma variável categórica possui noção de ordem, a codificação ordinal é bem apropriada. Neste modelo, utilizamos uma sequência de inteiros para representar cada variável. Por exemplo, podemos substituir os dias da semana (segunda, terça, etc.) pelos inteiros 1, 2, 3 e assim sucessivamente.

Codificação por Contagem ou Frequência

Aqui nós substituímos a categoria pelo número de ocorrências (ou a frequência, em porcentagem) desta no dataset. Conceitualmente, a categoria com maior representatividade será representada pelo maior valor numérico.

Peso da Evidência

Para tarefas de classificação/predição, o peso da evidência é uma boa metodologia de codificação. Este valor é calculado com base nas probabilidades da categoria indicar o resultado esperado.

Como exemplo, se quisermos prever se um determinado aluno apresentará evasão com base na sua formação de ensino médio, categorizada em **público, privado**:

1. Olhamos para todos os casos em que o aluno vem de escola **pública** e apresentou evasão. A probabilidade $P(1)$ é a proporção desses casos em relação ao total.
2. Fazemos o mesmo para os casos em que o aluno vem da escola **pública** e não evadiu. Calculamos a probabilidade $P(0)$ com a proporção desses casos.
3. A codificação da categoria será o logaritmo natural da divisão destas probabilidades.
4. Repetimos os passos para cada categoria

O fator interessante dessa metodologia é que ela codifica uma relação monotônica da variável e do alvo: quanto maior a probabilidade de ser verdadeira ($P(1)$), maior o valor da codificação gerada.

Transformação de variável

A transformação de variável é a aplicação de funções matemáticas para alterar os valores originais dos dados. Isso pode ser importante quando temos uma escala que distorce as interpretações (dados financeiros com valores muito altos em um gráfico, por exemplo), ou quando precisamos adaptar os dados às premissas dos algoritmos: a regressão linear exige uma distribuição normal, por exemplo.

Transformação Logarítmica

O dado final é o logaritmo, usualmente base 2 ou 10, do valor original. Muito usada para transformar dados que crescem exponencialmente (juros compostos, mercado financeiro, etc.). Essa transformação, se aplicada a uma distribuição enviesada à esquerda (a maioria dos dados tem valor baixo e alguns dados tem valor muito alto), aproxima os dados de uma distribuição normal.

As maiores vantagens dessa transformação é que ela comprime os valores muito altos enquanto expande os valores baixos. Isso estabiliza a variância (reduz as discrepâncias) e transforma relações multiplicativas em aditivas ().

Transformação Recíproca

A recíproca pode ser entendida como o inverso. Nesta transformação, o dado x é substituído por $1/x$. Ela serve para inverter as taxas/razões (quilômetro por litro em transformar litro por quilômetro) expressas pelos dados. A transformação é muito eficiente para comprimir valores altos.

É preciso tomar um cuidado quando temos valores próximos do zero no denominador, pois a divisão pode gerar valores extremamente altos. Também deve-se ter em mente que a ordem das observações é invertida: o

que era o maior valor passa a ser o menor após a transformação.

Transformação por Raiz Quadrada

Temos essa transformação obtendo a raiz quadrada do valor original. Principalmente aplicada para dados que se originam de contagem (números de acesso).

Uma observação importante sobre essas transformações é que é importante manter o equilíbrio entre a performance da análise e a explicabilidade dos dados. Na visualização de dados, por exemplo, a interpretação de um gráfico em escala logarítmica é mais difícil do que na escala original.

Redução de Dimensionalidade

Ilustrar com gráficos de dados em 2 dimensões, 3 dimensões e mostrar dataset com 1000 colunas.
Quão simples é interpretar cada caso?

Embora possa ser considerada parte do conceito de *feature engineering*, a redução de dimensionalidade é uma ferramenta poderosa que exige aprofundamento próprio. Conjuntos de dados reais podem trazer um número exagerado de características, dificultando a interpretação dos dados e reduzindo a performance dos modelos.

A dificuldade de trabalhar com dados multidimensionais também é conhecida como a maldição da dimensionalidade: conforme a dimensionalidade dos dados aumenta, menos interpretáveis eles se tornam. Isso se dá porque, em múltiplas dimensões, os dados se tornam naturalmente mais dispersos.

Isso é ilustrado pela distância entre 2 pontos escolhidos aleatoriamente:

- Em 2 dimensões a distância média é 0,52
- Em 3D, a média sobe para 0,66
- Se subimos a 100.000 dimensões, a distância média torna-se 408,25

Essa distância também prejudica a performance de modelos de machine learning.

A ideia da redução de dimensionalidade é **remover** a informação menos importante, ou informações *não informacionais*. Observando essa distribuição dos pontos em 2D, que se aproxima de uma função puramente linear ($y=2x$), os valores de y não condicam muita informação relevante, certo? Agora, se olhamos para a distribuição seguinte, a relação entre os eixos é mais complexa e, portanto, podemos assumir que ela codifica informação mais relevante.

Se imaginamos nossos dados em um espaço geométrico com dimensões N , a redução de dimensionalidade equivale a projetar estes dados (cada ponto no espaço) em um espaço dimensional K , onde $K < n$. Por exemplo, se temos dados tridimensionais, a redução de dimensionalidade seria equivalente a projetá-los em um plano.

O grande problema está em como definimos as coordenadas desse plano? Para um determinado espaço tridimensional, existem infinitas projeções bidimensionais que podemos utilizar. A escolha da melhor projeção é a base de fundamentos da técnica que veremos a seguir: PCA (Principal Component Analysis)

PCA

Breve revisão da estatística: questionar a turma sobre os conceitos de média, variância e covariância.

Média: tendência de centralidade dos dados, me diz qual o valor que estaria no **centro** de uma determinada característica ou eixo

Variância: medida de tendência que me diz a média de quão distantes da média os valores estão. A variância é a soma da distância individual de cada ponto da média, em razão do número de observações.

Covariância: variância mas aplicada a cada par de variável (X,Y). Me diz a direção de variação de uma característica em relação a outra, mas não codifica informação sobre a **força** dessa relação.

Pensem no gráfico exibido na imagem. Se precisamos escolher uma destas retas para projetar os dados, qual reta mantém a maior quantidade de informação? Dica: a resposta está ligada aos conceitos de estatística vistos anteriormente.

Se olharmos para as retas geradas, a nossa reta ideal é aquela que preserva a **maior variância** dos dados. Isso é visto quando olhamos para a distribuição dos pontos após a projeção: nas demais retas, os pontos tendem a ser comprimidos no centro da projeção. Na reta ótima, os pontos encontram-se bem distribuídos após a projeção, portanto, exibem maior variância.

A análise de componentes principais nos diz como calcular essa projeção, independente do número de dimensões do nosso dataset. Um ponto importante é que, antes de aplicar o PCA, todos os dados devem estar **centralizados**.

Se temos um ponto em um espaço, e queremos projetá-lo na reta definida pelo vetor $\mathbf{u}$, a projeção deste ponto é representada por um vetor $\mathbf{v}$ com magnitude definida por $\|(\mathbf{x}^T \mathbf{u})\mathbf{u}\|$. Esta magnitude representa a quantidade de informação preservada pela projeção: $\|(\mathbf{x}^T \mathbf{u})\|^2$. Sendo assim, o objetivo do PCA é encontrar a projeção $\mathbf{u}$ de maneira a maximizar o valor preservado para todos os pontos $\sum (\mathbf{x}^T \mathbf{u})^2$.

Com a derivação das equações, auxiliado pela função de Lagrange e o cálculo do gradiente (demonstrado na figura), chegamos a equação $\mathbf{C} \mathbf{u} = \lambda \mathbf{u}$. Essa equação é a mesma equação para os autovalores e autovetores da Matriz de Covariância dos dados. A matriz pode ser calculada agrupando os pares de características em formato matricial, formando uma matriz simétrica na diagonal.

Do resultado dessa operação, temos 2 dados relevantes:

1. Os autovalores codificam a quantidade de informação preservada pela projeção (autovetor) associada;
2. Os autovetores codificam a direção da projeção

Com isto em mãos, podemos entender que a melhor projeção é equivalente ao **autovetor** associado ao maior **autovalor** resultante. Ao projetar nossos pontos nesse novo vetor, os pontos resultantes serão uma **combinação linear** dos valores dos eixos originais $\mathbf{x}' = \alpha \mathbf{y} + \beta \mathbf{z}$. Nessa combinação, α e β representam o quanto cada característica contribui para aquele componente principal.

Sendo assim, a aplicação de PCA deve ser feita seguindo os passos:

1. Centralizar os dados
2. Calcular a matriz de Covariância
3. Calcular autovalores e autovetores
4. Ordenar de forma decrescente pelos autovalores
5. Projetar os dados no componente principal
6. Se desejamos mais dimensões, projetamos nos próximos componentes principais.

É importante entender que o PCA não seleciona características específicas para manter no dataset, mas **cria novas características** que são combinações lineares das originais. Isso significa que, se fazemos uma visualização, por exemplo, os eixos devem ser nomeados **PC1**, **PC2**, etc.

Mas, para um dataset multidimensional, quantas dimensões eu escolho? Existem diferentes métricas para cada área, mas no geral, é importante manter ao menos 60% da variância explicada no dataset final. Para entender o quanto da variância cada dimensão do PCA explica, podemos utilizar um gráfico de Scree.